



中国科学技术大学
University of Science and Technology of China

Agent Runtime 项目期末汇报

报告人：张贺淇 陈雨桥

中国科学技术大学

2026 年 7 月 2 日

- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结

- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结

本项目面向 Android 端侧智能体，构建一套可本地部署、可结构化执行、可观测且可扩展的 Agent Runtime。

项目主体由两条平级技术线协同组成：


- ▶ 端侧 LLM 推理框架：负责 Android 本地模型加载、推理、KV Cache、量化、GPU/Vulkan 优化，并提供兼容 OpenAI 的模型服务接口。
- ▶ Action Fabric 结构化执行系统：负责把模型生成的任务计划表示为 Action DAG，并完成校验、调度、执行、恢复和审计，同时把结构化 Action 映射到 Android SDK、系统服务、ContentResolver、Intent 和权限协调组件。

整体协作关系是：本地模型负责规划与生成，Action Fabric 负责可靠执行，并将任务落到具体 Android 系统能力上。

移动端 Agent 的瓶颈不只是模型参数规模，还包括：

- ▶ 本地推理延迟高，弱网络或离线场景不能依赖云端补偿。
- ▶ 多轮模型调用会放大端到端等待时间。
- ▶ 上下文窗口有限，工具结果反复进入 prompt 会快速膨胀。
- ▶ 手机内存、功耗、温控和后台执行限制更严格。
- ▶ Android 系统能力涉及权限、Intent、前台服务和用户确认。

因此，端侧 Agent 需要的是一个可靠的执行系统，而不只是一个会调用工具的模型。



传统做法把执行路径藏在自然语言上下文里。

主要问题

- ▶ 每一步成功后仍要回到模型判断下一步。
- ▶ 独立工具调用也容易被串行化。
- ▶ 执行历史以文本形式堆叠，不利于校验、调试、回放和审计。
- ▶ 失败恢复依赖模型临场判断，容易重复副作用。

对于移动端 Agent，执行链路应该从“推理驱动”转向“调度驱动”。

模型输出一次结构化计划，Runtime 显式维护依赖关系和状态；成功路径不反复唤醒模型，只有格式错误、节点失败、权限确认或异常恢复时才回退给模型。

目标	含义
可校验	执行前发现缺参、错参、未知工具、循环依赖
可调度	Runtime 根据 DAG 自动计算 ready set
可并行	互不依赖的节点可以批量异步执行
可恢复	失败后按副作用等级、重试预算和诊断信息处理
可审计	节点状态迁移、输出和诊断可记录、可回放


围绕多轮推理、上下文膨胀、隐式依赖和并行不足，业界方案正在从“让模型看到更多”转向“让模型每轮只看到最有用、最可信、最短的信息”，并把执行过程结构化。


业界方向	关键做法	设计启发
MCP / Tool Calling	标准化工具名称、schema、资源链接和工具元数据，让模型能可靠连接外部能力	工具需要清晰边界：模型负责选择能力，系统负责约束能力
Context engineering / management	write / select / compress / isolate；工具结果引用化；tool retrieval；热/温/冷上下文分层	上下文需要被管理：不是塞入全部历史，而是按需提供短、可信的信息
Workflow patterns	Anthropic 将 prompt chaining、routing、parallelization、orchestrator-workers 等归为 workflow 类模式	确定性执行路径适合沉淀为 Workflow，模型负责规划和处理开放问题
Structured Graph	arXiv 2604.11378 将 Agent Loop 视为 single-ready-unit scheduler，并提出把控制流提升为静态 DAG	执行过程需要显式化：依赖、并发、恢复不应只藏在自然语言历史中

业界正在把 Agent 从“长上下文里的连续对话”推进为“模型决策 + 结构化工具 + 可管理上下文 + Workflow 编排”的系统工程。

参考：MCP Introduction；Anthropic, *Building Effective Agents*；arXiv:2604.11378。

- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结





路线：Workflow YAML 表达计划，Rust Dispatcher 承担调度和恢复，Protocol Buffers + gRPC 打通跨语言执行链，Android Action Runtime 落地 Android 系统能力。

```
version: 1
id: device-report
steps:
  - id: device
    action: device_info
    inputs:
      includeHardware: true
  - id: network
    action: network_status
    inputs:
      includeDetails: true
  - id: power
    action: power_status
    inputs:
      includeDetails: true
  - id: final_report
    action: subagent
    inputs:
      prompt: "根据 ${device} ${network} ${power} 生成设备状态摘要。"
output: final_report
```

DAG 结构

device、network、power 互不依赖，可并发执行；final_report 依赖三者。

推理轮数与输出

主 Agent 控制链从约 4 轮（选三个工具 + 最终回答）降为 1 轮（生成完整计划）。成功后不再回主 Agent 临时总结；用户拿到的是首轮计划中 output: final_report 指定的节点结果。


缩减上下文


工具输出保存在 runtime state，下游通过 \${device} 等引用结果，避免完整工具历史反复进入模型上下文。

Engine 不询问模型“下一步是什么”，而是根据 DAG 和节点状态推进执行。

调度职责

- ▶ Loader 校验依赖、引用、缺参和循环。
- ▶ Dispatcher 维护节点状态并计算 ready set。
- ▶ 同一 ready set 内批量异步执行。
- ▶ 非幂等和高风险节点按策略受到串行约束。





这条链路让 Rust 调度层和 Android 能力层解耦，后续扩展 Action 不需要重写调度器。

Android Action Runtime 已注册 59 个 Android Action:

能力类别	代表 Action
设备与系统	device_info、system_info、power_status、storage_info
网络与连接	network_status、http_call、wifi_toggle、bluetooth_toggle
应用与 Intent	list_installed_apps、launch_app、intent_show_map、intent_compose_email
数据与文件	read_file、search_files、clipboard_read、clipboard_copy
个人信息	search_contacts、read_sms、list_calendar_events
媒体与传感	take_photo、record_audio、screenshot、screen_record

封装方式: 每个能力实现为结构化 Action, 定义输入数据类、输出数据类和 execute 逻辑; 只读能力通过 Android SDK、系统服务或 ContentResolver 查询; 应用交互能力通过标准 Intent 封装; 相机、录音、截图、通知等能力由专门协调组件处理权限、生命周期和系统授权。

策略不由模型自述，而由可信 registry metadata 注入：

治理维度	设计
风险等级	Low、Medium、High、Critical
副作用等级	Pure、Idempotent、NonIdempotent
用户确认	高风险节点进入 WaitingHuman
重试预算	按 action metadata 控制，非幂等失败不自动重试
超时控制	节点级超时，避免长时间阻塞
审计日志	记录节点状态迁移与诊断信息

模型不能伪造 policy、sideEffect、retryBudget、timeoutMs 等策略字段。


恢复机制的目标不是“失败后让模型重新猜一遍”，而是尽可能保留已完成的确定性执行，并把可修正的信息压缩反馈。

情况	Runtime 行为
纯节点失败	在重试预算内自动重试
幂等节点失败	可按策略重试，成功结果写入状态
非幂等节点失败	不自动重试，避免重复副作用
需要用户确认	进入 <code>WaitingHuman</code> ，批准后继续，拒绝后进入失败路径
格式或参数错误	生成诊断信息，交给上层 Agent App 做有限轮次修正

`DiagnosticContext` 记录失败节点、错误码、已完成节点状态和可恢复性；上层 Agent App 只反馈必要诊断，避免完整执行历史重新进入上下文。

Agent 封装

- ▶ 接收用户请求并调用端侧或兼容 OpenAI API 的模型服务。
- ▶ 将 Action Catalog 和约束注入给模型生成 Workflow。
- ▶ 成功路径直接渲染最终消息模板。
- ▶ 失败或用户拒绝时，反馈节点状态和诊断信息，进入有限轮次修正。



仓库路径: `examples/tauri-chatbot-android`

包体内容

- ▶ 前端：对话界面、模型配置、用户确认、Workflow 状态展示。
- ▶ Rust 后端：模型调用、Action Catalog 注入、YAML 解析、Dispatcher 执行。
- ▶ Android Action Runtime：Gradle 接入 `kotlin/kotlin-actions-runtime`，同 APK 内启动 Kotlin gRPC runtime。

验证链路

模型输出 fenced YAML workflow 与最终消息模板；Dispatcher 通过 gRPC 调用 Kotlin 侧结构化 Action；成功后直接渲染首轮计划中的最终模板，回到 Agent App 界面。





- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力**
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结

Action Fabric 的竞争力来自“执行系统化”:


维度	传统 Agent Loop	Action Fabric
控制流	隐含在上下文	显式 DAG
模型调用	每步调用	成功路径一次规划
并发能力	通常串行	ready set 并发
中间结果	反复进入 prompt	Runtime 状态保存
安全策略	依赖提示词约束	可信 metadata 注入
可测试性	对话历史难复现	Workflow 可保存、回放、benchmark

传统 loop 中，工具成功后仍要让模型重新决定下一步。

Action Fabric 中，确定性后续动作由 DAG 边表达：

- ▶ 模型一次性输出 Workflow。
- ▶ Loader 校验依赖。
- ▶ Dispatcher 自动推进后续节点。
- ▶ 只有错误、拒绝或需要修正时才重新进入模型。

这直接降低端到端延迟，也降低端侧模型功耗压力。



独立节点可以在同一 ready set 中并发执行。fan-out/fan-in 类任务的 wall-clock time 接近关键路径，而不是所有节点耗时之和。

在传统 Agent Loop 中：

- ▶ 每次工具结果都可能被塞回模型上下文。
- ▶ 大体积 observation 会让 prompt 持续膨胀。
- ▶ 端侧小模型更容易遇到上下文窗口、内存和延迟问题。

在 Action Fabric 中：

- ▶ 工具结果存入 runtime state。
- ▶ 节点间通过 `${node_id}` 引用传递。
- ▶ 模型不必反复读取完整历史和大体积中间结果。

每个 Action 都有：

- ▶ 明确名称。
- ▶ 类型化输入输出。
- ▶ 风险等级。
- ▶ 副作用等级。
- ▶ 确认策略。
- ▶ 超时和重试预算。
- ▶ 是否允许被 subagent 调用。

这使得系统能在执行前发现问题，并在执行中控制风险，而不是依赖模型临场遵守自然语言提示。

Heavy subagent

- ▶ 为每个子任务启动较完整的 agent loop。
- ▶ 需要独立 prompt、上下文和 todo list。
- ▶ 多轮“计划-执行-观察-修正”带来额外模型调用。
- ▶ 自然语言 todo 仍要靠 LLM 在后续循环中隐式遵守。

Action Graph

- ▶ 不创建多个完整 agent，而是创建 runtime 可执行图。
- ▶ 普通工具节点不需要自己的 history 或 todo list。
- ▶ 明确输入、输出和依赖关系即可被调度执行。
- ▶ 开放推理才交给 subagent，确定性分解交给 runtime。

在移动端资源受限时，Action Graph 能以更低上下文成本和更少模型轮次表达类似任务分解能力；评测中模型调用从 17 次降至 1 次。



- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测**
- 5 端侧 LLM 推理引擎
- 6 项目总结

模块	完成情况
Workflow YAML 与 DAG 构建	已完成
DAG 校验、Ready Set 与并发调度	已完成
状态机、策略控制和审计	已完成
Rust-Kotlin gRPC 执行桥	已完成
Android Action Runtime 与 59 个 Action	已完成
完整 Agent App	已完成
Action Graph vs Agent Loop benchmark	已完成

Benchmark 路径: `rust/dispatcher/examples/action_graph_benchmark.rs`

Runner	说明
<code>action_graph</code>	使用真实 <code>dispatcher::Engine</code> 、 <code>ready set</code> 和 <code>execute_batch</code>
<code>agent_loop_full</code>	每一步完整 <code>observation</code> 回到模型上下文
<code>agent_loop_compact</code>	压缩 <code>observation</code> 的传统 <code>loop</code>
<code>heavy_subagent</code>	多子任务使用 <code>heavy subagent</code>

工作负载覆盖确定性流水线、fan-out/fan-in、大体积工具输出、失败恢复和子任务分解。指标包括端到端延迟、p95、模型调用次数、上下文输入量和最大并发宽度。

场景	Action Graph	对照方案	主要结论
12 步确定性流水线	433.4 ms	Agent Loop 3760.8 ms	延迟降低 88.5%，模型调用 12 次降至 1 次
16 路 fan-out/fan-in 5 步、每步 1MB 输出	327.7 ms 5.7 KB prompt	Agent Loop 5316.6 ms Loop full 10266.1 KB prompt	最大并发宽度从 1 提升至 16 工具结果不反复进入模型上下文
20% transient failure	410.5 ms	Agent Loop 3135.6 ms	存在失败时，成功节点仍由 runtime 推进
5 个子任务 × 3 步	347.5 ms	Heavy subagent 1548.0 ms	模型调用 17 次降至 1 次，上 下文减少 92.4%

这些结果说明，Action Graph 的价值不是单纯“结构更清晰”，而是转化为低延迟、低上下文压力、低模型调用次数、更强并行能力和更稳定成功路径。



- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结

端侧推理引擎不能只是跑一个模型，而要成为 Android 上实时高效可管理的本地系统服务。

目标	端侧要求	对应设计
低时延	弱网/离线也要可交互	Q8 prefill、decode GEMV、GPU LM head、流式回调
隐私	用户数据不应反复上传到云端	本地 OpenAI-style API + Android 权限侧治理
可控	请求可取消，模型可释放，错误可诊断	native queue、cancel/release、/health telemetry
长任务	Agent prompt、工具协议和上下文会重复出现	Paged KV Cache、pinned prefix、chunked prefill

端侧 AI 框架的难点在于能否在移动设备低性能约束下持续、稳定、可观测地服务 Agent。



llama.cpp 提供

- ▶ GGUF 模型生态与 tokenizer。
- ▶ sampler、CPU fallback、基础推理接口。
- ▶ C/C++ 工程基础和模型加载路径。

我们补上

- ▶ Android JNI / HTTP 服务层。
- ▶
- ▶ KV / prefix 内存管理与请求调度。
- ▶ Adreno 定制 Q8 Vulkan 后端与实机 gate。
- ▶ stream、cancel、release、health 生命周期。

设计边界	说明
不重写模型生态 重写系统边界	继续使用 GGUF / tokenizer / sampler，避免脱离 llama.cpp 社区资产。 Android 驱动、内存驻留、队列、缓存、telemetry 是端侧 Agent 的真实短板。


OpenCL：部署边界失败

- ▶ Android NDK 并不保证普通 App 可稳定使用 OpenCL。
- ▶ `vendor libOpenCL.so` 与依赖受 linker namespace 隔离。
- ▶ root / Magisk 级绕过不符合可部署 Runtime 目标。

ggml Vulkan：正确性边界失败

- ▶ Adreno 650 主要保证 Vulkan 1.1，安卓驱动层对 1.2/1.3 的支持不稳定
- ▶ 降低版本检查后能初始化、加载，但生成曾出现乱码
- ▶ 驱动层面 shader / buffer 语义不可控

因此 Android CMake 中显式关闭 `GGML_OPENCL` 和 `GGML_VULKAN`，保留 llama.cpp 模型生态，同时用可控的 Vulkan 1.1 kernel、正确性 gate 和 telemetry 重建端侧 GPU 执行边界。



移动端没有服务器级显存冗余。端侧 Runtime 需要显式管理哪些工作留在 CPU、哪些张量常驻 GPU，以及何时复用 KV。

	Runtime 实现	效果
控制面 / 数据面	CPU 负责 tokenize、sampler、队列、cache policy；GPU 负责 Q8 投影、LM head、top-k	控制逻辑保持灵活，密集计算留给 GPU
工作集	活跃 prompt、Q8 权重、packed KV、临时 attention buffer	避免不必要的 CPU/GPU 重复驻留
页缓存	prefix cache page pool，按 token page 复用 K/V	重复协议 prompt 不再完整 prefill



Paged / Prefix 思路

- ▶ 受 vLLM 启发: KV 不是一整块不可分割数组, 而是可复用的 page。
- ▶ 固定系统提示词、工具协议、subagent 协议进入 pinned prefix。
- ▶ 普通对话使用 dynamic entry, 采用 LRU 回收策略。

Action Fabric 会产生大量短生命周期 subagent：它们共享工具协议，但不应该继承完整聊天历史。我们把这个 workload 单独建模，而不是让它混在普通 chat cache 里。

场景	普通处理	我们处理
固定工具协议	每个 subagent 重新 prefill	stateless_subagent=true, 协议 prompt 进入 pinned prefix
并发短任务	多份重复系统提示词挤占 KV	一个 pinned entry 被多轮不同任务复用
普通聊天	可能和 subagent cache 混淆	chat cache key 与 subagent cache key 分离

模型	Cold TTFT	Warm TTFT	结论
0.6B-Q8_0	1249.13 ms	278.543 ms	TTFT 降低 77.7%
1.7B-Q8_0	2787.45 ms	610.29 ms	TTFT 降低 78.1%

当前引擎提供 OpenAI-compatible HTTP 接口，但内部不是同步函数调用，而是带状态的 native request queue。

- ▶ active_request 与 pending queue 分离。
- ▶ cancel/release 可作用于 active 与 queued request。
- ▶ max_pending_requests 提供背压。
- ▶ prefix-aware-aging-v2 兼顾 cache hit 与防饥饿。

理论	对应实现
短作业优先	prefix hit 请求服务时间更短
Aging	cache miss 请求不会长期等待
临界区	request state 使用锁与条件变量保护
背压	pending queue 限制避免 UI/服务被拖垮

模块	做法	实机意义
Q8_0 权重常驻	使用 GGUF 原生 Q8_0 tensor, 减少重复展开与复制	给 8K context 和 1.7B 模型留下内存空间
W8A8 prefill	activation 动态 Q8, packed int8 dot, F32 accumulate	TTFT 主路径从 F16 prefill 7361.61 ms 降到 788.56 ms
decode Q8 GEMV	nt == 1 走 subgroup GEMV_Q8	0.6B TPS +20.3%, 1.7B TPS +37.3%
GPU LM head	dot/top-k/merge 在 GPU 完成, 只回传候选集	避免全词表 logits 搬回 CPU
descriptor cache	热路径 descriptor alloc 归零作为 gate	防止系统调用开销吞掉 kernel 收益

阶段	git 历史中的工作	解决的问题
Android 闭环	Android Studio、CPU 推理、OpenAI API、configureBackend	App 能调用模型服务
驱动探索	原生 Vulkan 加载成功但乱码；MNN Vulkan 基础设施；自研 compute shader	证明原生路径不可控，转向可控后端
KV / prefill	加 KV cache、LRU 管理、prefill 分块、GPU prefill、LM head 优化	降低 TTFT 与重复 prompt 成本
Q8 化	原生 Q8_0、decode Q8、Q8_0 单份权重驻留	降低内存与 decode latency
扩展性	8K context、Qwen3-1.7B、消除 CPU 重复驻留	从 demo 模型走向可用端侧模型
Agent 化	stateless subagent cache 策略	针对 Action Fabric 的真实 workload 优化

我们在红米 K40 真机 (Adreno 650, 12GB RAM) 上跑 Qwen3 系列 0.6B-Q8_0 和 1.7B-Q8_0 模型, 使用真实的 Agent prompt 序列, 测量平均 TTFT、TPS

指标	0.6B-Q8_0	1.7B-Q8_0	说明
原有 TTFT median	1249.13 ms	2787.45 ms	decode Q8 GEMV 默认路径, 分别提升 77.7% 和 78.1%
最新 TTFT median	278.543 ms	610.29 ms	
原有 TPS median	3.6718	1.9954	相比旧 baseline, decode 速度分别提升 85.4% 和 103.3%
最新 TPS median	6.8382	4.0614	

上层 Action Fabric 把 Agent 执行变成可校验、可调度、可恢复的 DAG；下层 OSH26 LLM Runtime 把本地模型变成可调度、可复用、可观测的系统服务。

Action Fabric 需求	LLM Runtime 支撑
一次规划 Workflow 大量短 subagent ready set 并发 失败恢复 上下文治理	本地低 TTFT 模型服务，减少云端依赖 stateless prompt + pinned prefix cache native queue、背压、prefix-aware aging cancel、release、last error、token IDs、health telemetry 普通 chat 与 subagent cache 隔离，避免上下文污染

最终贡献：一个把模型、内存、驱动、调度、Action 执行统一起来的端侧 Agent Runtime。

- 1 项目背景与定位
- 2 系统架构与技术路线
- 3 核心竞争力
- 4 评测
- 5 端侧 LLM 推理引擎
- 6 项目总结**

本项目面向 Android 端侧智能体，构建本地部署、结构化执行、可观测、可扩展的 Agent Runtime，由端侧 LLM 推理框架与 Action Fabric 协同组成。

端侧 LLM 推理框架

基于 llama.cpp 与 GGUF 生态，重写适配 Adreno GPU 的 Vulkan 后端，支持 Qwen3 等小模型本地运行，并通过 Vulkan GPU 加速、Paged KV Cache、针对性 Prefix Cache 与 Q8_0 量化，降低推理延迟、内存占用和功耗，较现有端侧框架更适合高并发、上下文格式固定的 Agent 场景。

Action Fabric

将模型生成的任务计划结构化为有向无环图，由 Rust 调度内核完成依赖校验、Ready Set 并发调度、策略控制、失败恢复、状态存储与审计，并通过 gRPC 调用 Kotlin 侧 59 个结构化 Action。

相比传统 Agent Loop，该方案减少模型往返，降低延迟与上下文成本；相比零散工具调用，具备类型化输入输出、可信 metadata、确认门控、风险等级、副作用约束、可复现回放和工程化测试能力；相比 heavy subagent，可用更轻量的 Action 节点完成任务分解。

方向	成员	GitHub
Action Fabric	张贺淇 (负责人)	@zhangheqi
	杨家越	@jryyangjy
	贺秋实	@SurgeHe
端侧 LLM 部署与优化	陈雨桥 (负责人)	@SiriusPaul
	周子墨	@alizhouzimo



谢谢!